



XXIX ENMC
ENCONTRO NACIONAL DE MODELAGEM COMPUTACIONAL

XVII ECTM
ENCONTRO DE CIÊNCIA E TECNOLOGIA DE MATERIAIS

PROSPECÇÃO INTELIGENTE DE BIOATIVOS PARA BIOCENSORES ENZIMÁTICOS USANDO DEEP LEARNING

Primeiro Autor¹ – e-mail

Segundo Autor² – e-mail

Terceiro Autor³ – e-mail

1 Instituição do primeiro autor – Cidade – UF

2 Instituição do segundo autor – Cidade – UF

3 Instituição do terceiro autor – Cidade – UF

Resumo. Este trabalho apresenta uma abordagem computacional para prospecção de bioativos candidatos ao desenvolvimento de biossensores enzimáticos, com ênfase na inserção do modelo DrugCLIP em um pipeline de target fishing. A proposta parte da hipótese de que a busca por proteínas ou enzimas com potencial de interação com analitos de interesse pode ser tratada como uma tarefa de recuperação densa entre representações de ligantes e pockets proteicos. O procedimento implementado recebe um ligante de referência, gera ou organiza sua representação molecular, compara essa representação com uma biblioteca de pockets e produz um ranqueamento inicial de complexos proteína--ligante. Como a saída bruta tende a conter múltiplas estruturas, pockets e registros associados à mesma proteína, o pipeline inclui uma etapa de pós-processamento para agregação por proteína, redução de redundância e reorganização dos candidatos em uma lista mais interpretável. A abordagem não substitui ensaios experimentais, mas oferece uma estratégia de priorização para orientar estudos posteriores de bioafinidade, inibição enzimática e viabilidade de imobilização em plataformas biossensoras.

Palavras-chaves: Biossensores enzimáticos, DrugCLIP, Target fishing, Triagem virtual inversa, Bioativos.

1. INTRODUÇÃO

Biossensores enzimáticos constituem uma classe de dispositivos analíticos nos quais um elemento biológico de reconhecimento é acoplado a um transdutor capaz de converter um evento bioquímico em sinal mensurável. Em aplicações ambientais e alimentares, tais dispositivos são de interesse por combinarem especificidade molecular, potencial de miniaturização, operação em campo e possibilidade de reduzir dependência de procedimentos analíticos mais lentos ou custosos. No entanto, o desempenho de um biossensor não depende apenas do transdutor ou da eletrônica de leitura; ele é fortemente condicionado pela escolha do elemento biológico, pela estabilidade desse elemento e pela pertinência da interação entre analito e bioativo.

A seleção de proteínas, enzimas ou pockets com potencial de reconhecimento molecular ainda é uma etapa crítica. Em muitos casos, a busca por candidatos depende de leitura manual de bases de dados, análise de artigos, consulta a repositórios estruturais e interpretação funcional de proteínas. Esse processo é particularmente complexo quando o objetivo não é apenas confirmar um alvo molecular conhecido, mas prospectar candidatos alternativos para uso em biossensores. Nesse cenário, métodos de aprendizado de máquina podem atuar como

ferramentas de triagem e priorização, permitindo reorganizar grandes coleções de estruturas moleculares em listas de candidatos mais manejáveis.

Este artigo descreve uma abordagem baseada na inserção do DrugCLIP em um pipeline de target fishing orientado à prospecção de bioativos. O DrugCLIP foi originalmente proposto como uma estrutura de aprendizado contrastivo para triagem virtual, reformulando o problema como uma tarefa de recuperação densa entre representações de moléculas e pockets proteicos (Gao et al., 2023). Essa formulação é particularmente interessante para o problema aqui tratado, pois permite inverter parcialmente a lógica usual da triagem: em vez de partir de um alvo e buscar moléculas ativas, parte-se de um ligante ou analito de interesse e busca-se uma lista de pockets e proteínas potencialmente compatíveis.

O objetivo do trabalho é apresentar a estrutura de implementação do pipeline, destacando: a representação do ligante, o uso do DrugCLIP como mecanismo de recuperação, a geração de ranking de complexos, a distinção entre complexos, pockets, estruturas e proteínas, e a posterior agregação dos resultados por proteína. A contribuição principal está na organização do resultado bruto do target fishing em uma forma mais adequada ao problema de engenharia de biossensores, no qual a unidade de decisão tende a ser o bioativo candidato e não cada complexo estrutural isolado.

2. FUNDAMENTOS TÉCNICOS

2.1. Biossensores enzimáticos e escolha do bioativo

Um biossensor pode ser compreendido como a integração entre um elemento de reconhecimento, um transdutor e uma unidade de processamento ou leitura. O elemento de reconhecimento pode ser uma enzima, anticorpo, ácido nucleico, célula, aptâmero ou outro componente molecular capaz de responder seletivamente a um analito. Em biossensores enzimáticos, essa resposta pode decorrer de uma reação catalítica, da formação de complexo molecular ou de um processo de inibição enzimática. Revisões sobre transdutores e biossensores destacam que a escolha adequada do bioreceptor e sua imobilização sobre a plataforma sensora são etapas determinantes para sensibilidade, seletividade e estabilidade (Polat et al., 2022; Marques e Yamanaka, 2008).

No contexto de biossensores baseados em inibição, o analito pode atuar reduzindo a atividade de uma enzima, e essa redução é convertida em sinal analítico. Esse princípio é relevante para contaminantes ambientais, pesticidas, metais, toxinas e outros compostos capazes de modular atividade enzimática. Assim, a prospecção de bioativos não se reduz a encontrar uma proteína que se ligue a um ligante: é necessário considerar também plausibilidade bioquímica, função enzimática, disponibilidade de dados estruturais, possibilidade de imobilização e compatibilidade com a técnica de transdução pretendida.

2.2. Target fishing e triagem virtual inversa

Target fishing é uma estratégia computacional voltada à identificação de possíveis alvos moleculares associados a uma molécula de interesse. Em descoberta de fármacos, a técnica é frequentemente usada para inferir proteínas que possam interagir com um ligante. Em uma abordagem orientada a biossensores, essa mesma lógica pode ser reinterpretada: o interesse não é necessariamente descobrir um alvo terapêutico, mas identificar proteínas ou enzimas que possam funcionar como candidatos a elementos de reconhecimento ou como referências para estudos de interação analito-bioativo.

A triagem virtual inversa opera em sentido complementar à triagem virtual convencional. Na triagem convencional, parte-se de uma proteína ou pocket e busca-se, em uma biblioteca de moléculas, aquelas com maior probabilidade de ligação. Na triagem inversa, parte-se do ligante e busca-se um conjunto de proteínas ou pockets compatíveis. Essa inversão é

adequada quando o analito já é conhecido, mas o elemento biológico de reconhecimento ainda precisa ser escolhido ou ampliado.

2.3. DrugCLIP como modelo de recuperação proteína-molécula

O DrugCLIP propõe uma formulação contrastiva para o problema de triagem virtual. Em vez de depender apenas de funções supervisionadas de predição de afinidade, o modelo aprende representações de moléculas e pockets em um espaço comum, aproximando pares compatíveis e afastando pares não correspondentes. A formulação original descreve a triagem virtual como tarefa de recuperação densa, alinhando representações de pockets proteicos e moléculas a partir de dados pareados, mesmo sem exigir escores explícitos de afinidade para todos os exemplos (Gao et al., 2023).

Essa característica torna o DrugCLIP útil para pipelines de busca em larga escala. Uma vez calculadas as representações dos pockets e do ligante de consulta, a comparação pode ser realizada por medidas de similaridade no espaço de embeddings. O resultado é uma lista ordenada de pockets ou complexos candidatos, que pode ser posteriormente filtrada, agregada e interpretada. Para biossensores, esse resultado deve ser tratado como evidência computacional preliminar, não como confirmação experimental de ligação ou atividade.

3. METODOLOGIA

A metodologia foi estruturada como um pipeline computacional de triagem virtual inversa. O fluxo geral é apresentado na Figura 1. O processo foi concebido para receber um ligante de interesse, consultar uma biblioteca de pockets proteicos, recuperar candidatos por similaridade no espaço de representações do DrugCLIP e reorganizar a saída em um ranking por proteína.



Figura 1. Fluxo conceitual do pipeline de target fishing baseado em DrugCLIP.

3.1. Entrada molecular e padronização do ligante

A entrada do pipeline é uma molécula de referência, representada preferencialmente por SMILES, estrutura 2D/3D ou arquivo molecular equivalente. Antes da consulta, a molécula deve passar por uma etapa de padronização, incluindo verificação de valência, remoção ou tratamento de sais quando aplicável, geração de conformações e conversão para o formato esperado pelo codificador molecular. Essa etapa é necessária porque variações aparentemente pequenas na representação computacional podem alterar a forma como o modelo calcula o embedding do ligante.

No caso de analitos ambientais, como toxinas, pesticidas ou metabólitos, a curadoria molecular deve ser especialmente cuidadosa. Muitos compostos possuem estereoquímica relevante, grupos ionizáveis ou formas tautomericamente alternativas. Assim, a preparação do ligante deve registrar as decisões adotadas, para permitir reprodutibilidade e interpretação posterior do resultado.

3.2. Biblioteca de pockets e complexos candidatos

A segunda entrada do pipeline é uma biblioteca de pockets proteicos. Cada pocket pode estar associado a uma estrutura experimental, a uma proteína, a um identificador de complexo ou a metadados provenientes de bases estruturais e funcionais. Para uso em target fishing, a biblioteca deve preservar a relação entre quatro níveis de informação: pocket, estrutura, complexo e proteína. Essa distinção é essencial, pois uma mesma proteína pode aparecer em diferentes estruturas, conformações, estados de ligação ou organismos relacionados.

O pocket é tratado como a região espacial diretamente comparada ao ligante pelo modelo. A estrutura corresponde ao arquivo ou entrada estrutural que contém esse pocket. O complexo representa a associação entre uma estrutura proteica e um ligante ou molécula de referência. A proteína, por sua vez, é a entidade biológica de maior interesse para a prospecção de bioativos. A implementação deve manter essas relações para que o ranking bruto, inicialmente estrutural, possa ser reinterpretado biologicamente.

3.3. Inserção do DrugCLIP no pipeline

O DrugCLIP foi inserido como componente de recuperação. Para cada consulta, o ligante é codificado no espaço latente do modelo, enquanto os pockets da biblioteca são representados no mesmo espaço ou recuperados de um índice previamente calculado. A comparação entre embeddings gera escores de similaridade, a partir dos quais é produzido um ranking inicial de pockets ou complexos candidatos.

Do ponto de vista computacional, essa escolha permite separar três responsabilidades: preparação dos dados moleculares, inferência do modelo e pós-processamento dos resultados. Essa separação facilita manutenção, reprodutibilidade e substituição futura de módulos. Em particular, o componente de inferência pode ser mantido independente das regras de curadoria biológica, enquanto o pós-processamento pode incorporar critérios específicos de biossensores sem alterar o modelo base.

3.4. Pós-processamento e agregação por proteína

A saída bruta do target fishing tende a ser uma lista de complexos, não uma lista de proteínas únicas. Isso produz redundância quando diferentes pockets, estruturas ou entradas correspondem à mesma proteína ou a proteínas altamente similares. Para tornar o resultado útil à prospecção de bioativos, foi definida uma etapa de agregação por proteína. Nessa etapa, os registros são normalizados, agrupados por identificador proteico e resumidos por métricas derivadas dos escores dos complexos associados.

A agregação pode considerar, no mínimo, o melhor escore associado à proteína, a frequência de ocorrência no ranking, a posição média ou mediana dos complexos relacionados, a diversidade de pockets encontrados e a consistência funcional da proteína com o uso pretendido. A Tabela 1 sintetiza os principais critérios considerados.

Tabela 1. Critérios de consolidação do ranking por proteína.

Critério	Descrição	Utilidade	Limitação
Melhor escore	Maior similaridade obtida entre ligante e pockets associados à proteína.	Preserva o candidato estruturalmente mais favorável.	Pode supervalorizar uma única ocorrência.
Frequência	Número de registros da proteína entre os complexos ranqueados.	Indica recorrência do sinal computacional.	Pode refletir redundância da base.
Mediana dos escores	Tendência central dos escores associados à proteína.	Reduz efeito de valores extremos.	Depende do número de registros.
Diversidade de pockets	Quantidade de pockets distintos vinculados à proteína.	Sugere robustez estrutural da indicação.	Requer curadoria dos identificadores.
Consistência funcional	Compatibilidade entre função conhecida e hipótese biossensora.	Aproxima o ranking da interpretação bioquímica.	Depende de anotação funcional confiável.

4. RESULTADOS E DISCUSSÃO

A implementação do pipeline permitiu organizar o target fishing em duas camadas complementares: uma camada estrutural, centrada em pockets e complexos, e uma camada biológica, centrada em proteínas candidatas. Essa separação é relevante porque o resultado diretamente produzido por modelos de recuperação proteína--molécula não coincide necessariamente com a forma mais adequada de decisão para engenharia de biossensores.

Na camada estrutural, o ranking informa quais pockets apresentam maior proximidade ao ligante no espaço de embeddings. Na camada biológica, os resultados são consolidados para responder a uma pergunta diferente: quais proteínas merecem prioridade como candidatas a bioativos ou como referências para estudos de interação? A passagem de uma camada para outra constitui uma etapa metodológica importante da abordagem proposta.

4.1. Natureza do resultado bruto

O resultado bruto do target fishing é uma lista ordenada de complexos ou pockets. Essa lista é informativa, mas pode ser enganosa se interpretada diretamente como lista de proteínas candidatas. Um mesmo alvo proteico pode aparecer diversas vezes em razão de múltiplas estruturas cristalográficas, diferentes ligantes cocrystalizados, variantes de cadeia, estados conformacionais ou entradas redundantes. Sem tratamento adicional, proteínas com maior representação estrutural na base podem ocupar várias posições do ranking, enquanto proteínas menos representadas podem parecer artificialmente menos relevantes.

Essa característica não é uma falha específica do modelo, mas uma consequência do modo como bases estruturais são organizadas e de como tarefas de recuperação operam sobre pockets. Por isso, a interpretação dos resultados deve preservar a granularidade estrutural sem perder a visão consolidada por proteína.

4.2. Conversão de complexos em proteínas candidatas

A etapa de agregação transforma a lista de complexos em uma lista não redundante de proteínas candidatas. Essa transformação exige normalizar identificadores, resolver duplicidades e manter rastreabilidade entre proteína, estrutura, pocket e score. O melhor resultado para uma proteína não deve ser descartado, pois representa o pocket mais favorável encontrado; entretanto, ele deve ser acompanhado de indicadores adicionais, como frequência e distribuição dos scores.

A saída consolidada torna-se mais compatível com decisões de engenharia de biossensores. Em vez de apresentar dezenas de complexos semelhantes ao usuário, o pipeline pode exibir uma lista priorizada de proteínas, cada uma acompanhada por seus principais pockets, estruturas de suporte e métricas de confiança computacional. Esse formato facilita a escolha de candidatos para avaliação bioquímica, análise de literatura, comparação com mecanismos de inibição conhecidos e planejamento de ensaios posteriores.

4.3. Interpretação técnico-científica dos scores

Os scores derivados do DrugCLIP devem ser interpretados como medidas de compatibilidade no espaço de representações aprendido pelo modelo. Eles não equivalem diretamente a constantes de afinidade, energia livre de ligação ou atividade enzimática. Portanto, o ranking computacional deve ser entendido como instrumento de priorização. Essa distinção é importante para evitar inferências excessivas a partir de modelos de recuperação.

Em aplicações de biossensores, a proteína mais bem ranqueada não é necessariamente a melhor escolha experimental. Outros fatores podem ser decisivos: estabilidade da proteína, custo de obtenção, presença de cofatores, facilidade de imobilização, manutenção da atividade após fixação, seletividade frente a interferentes e compatibilidade com transdução eletroquímica, óptica ou outra. Assim, o ranking deve ser combinado com curadoria funcional e critérios de engenharia do dispositivo.

4.4. Contribuição da abordagem para biossensores enzimáticos

A principal contribuição da abordagem está em adaptar uma ferramenta originalmente associada à triagem virtual para um problema de prospecção de bioativos em biossensores. Essa adaptação desloca o uso do modelo: o interesse não está em selecionar fármacos para um alvo único, mas em identificar alvos potenciais para um analito conhecido. A combinação entre target fishing e agregação por proteína oferece uma forma de explorar bases estruturais e funcionais com maior sistematicidade.

Essa estratégia pode ser útil especialmente em fases iniciais de pesquisa, quando ainda há incerteza sobre quais proteínas ou enzimas devem ser consideradas. Ao reduzir a lista de candidatos e apresentar evidências estruturais associadas a cada proteína, o pipeline contribui para organizar a tomada de decisão e para reduzir buscas manuais dispersas. Ainda assim, sua utilidade final depende de validação com dados experimentais, comparação com literatura especializada e avaliação de desempenho em condições reais de biossensoriamento.

4.5. Limitações e cuidados metodológicos

A abordagem possui limitações. A primeira decorre da cobertura e qualidade das bases de pockets e complexos. Proteínas extensivamente estudadas tendem a possuir maior número de estruturas disponíveis, enquanto proteínas pouco caracterizadas podem estar sub-representadas. A segunda limitação está associada ao próprio treinamento do modelo, que reflete os padrões presentes nos dados usados para aprendizado. A terceira diz respeito à distância entre compatibilidade estrutural prevista e desempenho analítico de um biossensor.

Também é necessário considerar que um pocket favorável não garante que a proteína seja adequada como bioreceptor. A função natural da proteína, seu ambiente químico, sua estabilidade fora do contexto celular e sua resposta após imobilização são fatores que podem alterar completamente a viabilidade experimental. Portanto, a proposta deve ser vista como uma camada computacional de triagem, e não como etapa conclusiva de validação.

5. CONCLUSÕES

Foi apresentada uma abordagem computacional para prospecção de bioativos em biossensores enzimáticos baseada na inserção do DrugCLIP em um pipeline de target fishing. A formulação permite partir de um ligante de interesse e recuperar pockets proteicos compatíveis, produzindo um ranking inicial de complexos. Como esse resultado bruto contém redundâncias estruturais e múltiplos registros associados à mesma proteína, foi proposta uma etapa de pós-processamento para agregação por proteína e reorganização dos candidatos em uma lista mais interpretável.

O uso do DrugCLIP é tecnicamente adequado ao problema porque sua formulação contrastiva trata a triagem virtual como recuperação densa entre moléculas e pockets. Entretanto, os escores obtidos devem ser interpretados como indicadores computacionais de compatibilidade, não como medidas experimentais de afinidade ou atividade. A principal contribuição da implementação está em articular representação molecular, recuperação por embeddings e curadoria do ranking para aproximar a saída do modelo das necessidades de decisão em engenharia de biossensores.

Como trabalho futuro, recomenda-se ampliar a curadoria das bibliotecas de pockets, calibrar métricas de agregação por proteína, comparar rankings com dados experimentais disponíveis e avaliar a pertinência dos candidatos em estudos de inibição, estabilidade e imobilização. Essa integração entre triagem virtual inversa e critérios de biossensoriamento pode contribuir para tornar a prospecção de bioativos mais sistemática, rastreável e reproduzível.

AGRADECIMENTOS

Os autores agradecem aos laboratórios, grupos de pesquisa e instituições envolvidos no desenvolvimento científico e tecnológico que fundamentou este trabalho. A redação final dos agradecimentos deve ser ajustada conforme as exigências da submissão e as normas de financiamento aplicáveis.

6. REFERÊNCIAS

- AKKAŞ, T.; RESHADEGHI, M.; ŞEN, M.; KILIÇ, V.; HORZUM, N. The Role of Artificial Intelligence in Advancing Biosensor Technology: Past, Present, and Future Perspectives. *Advanced Materials*, 2025. DOI: 10.1002/adma.202504796.
- CAMPÀS, M.; MARTY, J.-L. Enzyme sensor for the electrochemical detection of the marine toxin okadaic acid. *Analytica Chimica Acta*, v. 605, p. 87–93, 2007. DOI: 10.1016/j.aca.2007.10.036.
- FDEZ-SANROMÁN, A.; BERNÁRDEZ-RODAS, N.; ROSALES, E.; PAZOS, M.; GONZÁLEZ-ROMERO, E.; SANROMÁN, M. A. Biosensor Technologies for Water Quality: Detection of Emerging Contaminants and Pathogens. *Biosensors*, v. 15, n. 189, 2025. DOI: 10.3390/bios15030189.
- GAO, B.; QIANG, B.; TAN, H.; JIA, Y.; REN, M.; LU, M.; LIU, J.; MA, W.-Y.; LAN, Y. DrugCLIP: Contrastive Protein-Molecule Representation Learning for Virtual Screening. In: *Advances in Neural Information Processing Systems 36*, NeurIPS 2023, 2023.
- KIM, T. H. Toward Emerging Innovations in Electrochemical Biosensing Technology. *Applied Sciences*, v. 11, n. 2461, 2021. DOI: 10.3390/app11062461.
- LAKARD, B. Electrochemical Biosensors Based on Conducting Polymers: A Review. *Applied Sciences*, v. 10, n. 6614, 2020. DOI: 10.3390/app10186614.
- MARQUES, P. R. B. O.; YAMANAKA, H. Biossensores baseados no processo de inibição enzimática. *Química Nova*, v. 31, n. 7, p. 1791–1799, 2008.
- NIGAM, V. K.; SHUKLA, P. Enzyme Based Biosensors for Detection of Environmental Pollutants - A Review. *Journal of Microbiology and Biotechnology*, v. 25, n. 11, p. 1773–1781, 2015. DOI: 10.4014/jmb.1504.04010.
- POLAT, E. O.; CETIN, M. M.; TABAK, A. F.; GÜVEN, E. B.; UYSAL, B. Ö.; ARSAN, T.; KABBANI, A.; HAMED, H.; GÜL, S. B. Transducer Technologies for Biosensors and Their Wearable Applications. *Biosensors*, v. 12, n. 385, 2022. DOI: 10.3390/bios12060385.

DRUGCLIP INSERTION INTO A TARGET FISHING PIPELINE FOR BIOACTIVE PROSPECTION IN ENZYMATIC BIOSENSORS

Abstract. *This work presents a computational approach for prospecting bioactive candidates for enzymatic biosensor development, emphasizing the insertion of DrugCLIP into a target fishing pipeline. The approach assumes that the search for proteins or enzymes potentially interacting with analytes of interest can be treated as a dense retrieval task between ligand and protein-pocket representations. The implemented procedure receives a reference ligand, organizes its molecular representation, compares it with a protein-pocket library, and produces an initial ranking of protein-ligand complexes. Since the raw output tends to contain multiple structures, pockets, and records associated with the same protein, the pipeline includes a post-processing step for protein-level aggregation, redundancy reduction, and reorganization of candidates into a more interpretable list. The approach does not replace experimental assays, but provides a prioritization strategy to guide subsequent studies on bioaffinity, enzymatic inhibition, and immobilization feasibility in biosensing platforms.*

Keywords: *Enzymatic biosensors, DrugCLIP, Target fishing, Inverse virtual screening, Bioactives.*